ML System Design Doc — Система автоматической транскрибации, диаризации и анализа эмоциональной окраски звонков колл-центра (MVP) v1

Паспорт документа

- Статус: рабочая версия для согласования пилота (MVP)
- Версия: `v1.0`
- Тип документа: `ML System Design Doc`
- Область применения: пилотный контур контроля качества звонков колл-центра
- Основа: шаблон ML System Design Doc (Reliable ML) + проектный черновик `draft.md`

Назначение документа

Документ фиксирует цели, ограничения, методологию, критерии успешности пилота и требования к MVP-системе автоматической обработки звонков колл-центра:

- автоматическая расшифровка (ASR),
- диаризация/атрибуция говорящих,
- определение эмоциональной окраски реплик,
- формирование аналитики и очереди приоритизации звонков для QA/супервизоров.

Документ предназначен для совместной работы `Product Owner`, `Data Scientist / ML Engineer`, `QA`, `DE` и технических команд, участвующих в подготовке пилота.

---

1. Цели и предпосылки

1.1. Зачем идем в разработку продукта?

Бизнес-цель (PO):

- Сократить стоимость и время ручного контроля качества (QA) звонков и повысить покрытие контроля (ближе к 100% звонков вместо выборочной проверки).

- Быстрее находить проблемные разговоры (негатив/конфликт) для работы супервизоров и обучения операторов.

- Получать регулярную аналитику по эмоциональному фону диалогов (клиент/оператор) для оценки клиентского опыта.

Почему ML улучшит текущий процесс (PO+DS):

- Ручная разметка/прослушивание плохо масштабируются, а записи пополняются ежедневно.
- Автоматическая расшифровка + эмоции по репликам позволяют:
  - строить “таймлайн” диалога,
  - быстро фильтровать звонки по негативу/эскалациям,
  - агрегировать показатели по операторам/командам/темам.

Успех итерации (бизнес) (PO):

- Система ежедневно обрабатывает звонки предыдущих суток и выдает результаты в понятном для QA/супервизоров формате.
- Супервизоры подтверждают полезность (экономия времени, повышение качества разбора кейсов).
- Достигнуты целевые технические метрики (см. ниже) и понятная связь с бизнес-эффектом (скорость QA, выявление проблемных звонков).

1.2. Бизнес-требования и ограничения

Бизнес-требования (PO):

- Вход: архив аудиозаписей колл-центра, пополнение каждый день в **00:00** (папки со звонками за предыдущие сутки).
- Выход по каждому звонку:
  - расшифровка с разбиением на реплики и таймкодами,
  - эмоциональная метка для каждой реплики,
  - агрегаты по звонку (доля негативных реплик, пиковые участки, “критические моменты”).
- Выход по группе (оператор/команда/период): агрегированная статистика эмоций и топ проблемных звонков.

Ограничения (PO):

- Персональные данные/конфиденциальность: записи разговоров могут содержать ПДн → требуется контроль доступа, шифрование, политика хранения и (возможно) маскирование чувствительных сущностей.
- Вычислительные ресурсы: ASR на аудио — самая дорогая часть, нужен расчет/лимиты на пилоте.
- Язык: предполагается русский (возможны вставки/код-свитч — уточнить).

Ожидания от итерации (PO):

- MVP “ночной батч”: обработка за сутки после появления папки (например, до 06:00 результаты готовы).
- Минимальная интеграция: выгрузка результатов в таблицу/витрину + простой отчет/дашборд.

Как модель используется в бизнес-процессе пилота (PO):

- Супервизор/QA получает список звонков с высоким “негативным индексом” и открывает карточку звонка:
  - таймлайн реплик (кто/когда/что сказал),
  - метки эмоций и уверенности,
  - быстрые переходы к “пиковым” моментам.
- Далее супервизор принимает действия (обратная связь оператору, обучение, эскалация кейса).

Успешный пилот (PO):

- Подтвержденный бизнес-эффект: снижение времени QA на 1 звонок и/или увеличение числа разобранных звонков на супервизора.
- Достаточная точность эмоций на реальных звонках (валидация на ручной разметке).

1.3. Что входит в скоуп итерации, что не входит

Входит (DS):

- Ночной pipeline:
    1. ingest новых аудио,
    2. ASR с таймкодами и разбиением,
    3. определение “кто говорит” (speaker) *в MVP — через VibeVoice-ASR либо упрощение*,
    4. эмоция для каждой реплики (4 класса),
    5. агрегации и выгрузка результатов.
- Модель эмоций: классификация реплик в 4 эмоции из датасета Dusha: **радость/positive, грусть, злость, нейтральная** (developers.sber.ru).
- Техническая воспроизводимость: контейнеризация, версионирование моделей и датасетов, фиксированные сплиты.

Не входит (DS):

- Предсказание исхода звонка, NPS, “оценка оператора” как единый скор (можно позже поверх эмоций/контента).
- Тематическое моделирование/ключевые причины обращений.
- Real-time обработка (стриминг) — позже.
- Полноценная PII-редакция (если потребуется, заложим как отдельный этап/итерацию).

Технический долг (DS):

- Доработка diarization (если качество недостаточно).
- Авто-сбор разметки на реальных звонках (active learning) — после пилота.
- Модель эмоций multimodal (аудио+текст) — опционально.

1.4. Предпосылки решения

- Данные пополняются **раз в сутки в 00:00**, значит целевой режим первой итерации — **batch-процессинг “за вчера”**.
- Для ASR рассматриваем:
  - **Whisper** (семантически сегментирует на интервалы с таймкодами; формат JSON/segments широко поддержан в экосистеме) (developers.openai.com)
  - **VibeVoice-ASR (Microsoft)** — важное преимущество: объединяет ASR + diarization + timestamps в одной генерации (“Who/When/What”), рассчитан на long-form до ~60 минут (huggingface.co)
- Эмоции: стартуем с 4-классовой схемы Dusha (developers.sber.ru), далее при необходимости расширяем (интенсивность/больше классов/доменные эмоции).

---

2. Методология (DS)

2.1. Постановка задачи

Система решает композицию задач:

1. **Speech-to-Text**: перевод аудиозаписи звонка в структурированный текст с таймкодами и разделением на реплики.
2. **Speaker attribution**: определение, кто говорит (оператор/клиент или Speaker0/Speaker1).
3. **Emotion classification**: многоклассовая классификация эмоции для каждой реплики (4 класса).
4. **Aggregation**: расчет признаков/метрик на уровне звонка и групп.

2.2. Блок-схема решения (baseline vs MVP)

Ниже — вариант для MVP (в baseline шаг “эмоции” можно заменить на готовую модель с Hugging Face/простую текстовую тональность).

```
flowchart TD
  A[Архив аудио: папка за сутки в 00:00] --> B[Ingest + регистрация метаданных звонков]
  B --> C[Preprocess: конвертация, нормализация, VAD]
  C --> D{ASR}
  D -->|Whisper| E[Сегменты с таймкодами]
  D -->|VibeVoice-ASR| F[Who/When/What: реплики + speaker + timestamps]
  E --> G[Speaker attribution: stereo split или diarization]
  F --> H[Готовые реплики со speaker]
  G --> H
  H --> I[Emotion model: 4 класса (радость/грусть/злость/нейтр.)]
  I --> J[Агрегации по звонку/оператору/периоду]
  J --> K[Хранилище результатов + отчет/дашборд]
```

Опора на возможности VibeVoice-ASR (структурная расшифровка с говорящими и таймкодами) снижает сложность отдельного diarization-шага (huggingface.co).

2.3. Этапы решения задачи

Этап 1 — Подготовка данных

Название данных	Есть ли данные в компании (источник/витрина)	Требуемый ресурс	Проверено ли качество данных
Архив аудиозаписей звонков	Да (файловое хранилище, ежедневные папки)	DE/DS/IT	Нет, требуется аудит форматов/битрейта/канальности на Этапе 1
Метаданные звонка (call_id, дата, оператор, длительность, направление и т.п.)	Ожидается, что есть в операционной системе колл-центра (DB/CSV-экспорт); конкретный источник фиксируется на kickoff	DE/DS/PO	Нет, источник и качество подтверждаются на Этапе 1
Ручные оценки QA (если есть)	Частично: возможны в QA-системе/таблицах; если отсутствуют, собираем пилотную разметку вручную	PO/QA/DE	Нет, наличие и структура проверяются на Этапе 1
Внешний датасет эмоций Dusha	Да (open dataset) (developers.sber.ru)	DS	n/a
Разметка эмоций на части реальных звонков (для доменной валидации)	Будет создана в пилоте	PO/QA/DS	n/a

Выход этапа:

- Описание схемы данных + каталог звонков (таблица “calls”).
- Скрипты проверки качества: битые файлы, пустой звук, необычно длинные/короткие звонки, распределение длительностей.
- Подготовленный сэмпл для EDA/экспериментов (например, N часов аудио, репрезентативно по очередям/операторам/времени).

Этап 2 — ASR (бейзлайн и MVP)

Baseline:

- Whisper (например, faster-whisper) → сегменты с таймкодами.
- Оценка качества: ручная проверка на подвыборке (WER/CER на размеченных вручную отрывках), плюс субъективная приемка супервизорами.

MVP:

- Сравнить Whisper vs VibeVoice-ASR на:
  - точности текста,
  - корректности сегментации “репликами”,
  - наличии speaker diarization “из коробки”.
- VibeVoice-ASR заявляет “Who/When/What” и diarization в едином выводе (huggingface.co) — это может существенно ускорить MVP.

Риски/план:

- Доменные термины/имена → использовать “hotwords/контекст” там, где поддерживается (VibeVoice) (huggingface.co).
- Низкое качество аудио/шумы → VAD, нормализация, (опционально) шумоподавление.

Этап 3 — Speaker attribution (кто говорит)

Baseline варианты (выбрать по данным):

1. Если записи **стерео** (оператор/клиент по каналам) → split L/R, разметка speaker по каналу (**предпочтительно, если доступно**).
2. Если моно → diarization (pyannote/WhisperX-подобный пайплайн) либо переход на VibeVoice-ASR.

MVP:

- Приоритет: VibeVoice-ASR, т.к. diarization встроен (huggingface.co).
- Маппинг Speaker0/Speaker1 → “оператор/клиент”:
  - через метаданные (кто начал разговор, приветствие, скриптовые фразы),
  - либо через канал (если стерео).

Этап 4 — Модель эмоций (реплика → 4 класса)

Целевая переменная:

- Emotion ∈ {радость/positive, грусть, злость, нейтральная} по аналогии с Dusha (developers.sber.ru).

Baseline:

- Вариант A: готовая текстовая модель (sentiment/тональность) + маппинг в 4 класса (тональность→радость/нейтр., токсичность/негатив→злость/грусть по правилам).
- Вариант B: готовая SER/Emotion модель с HF (если найдется приемлемая по RU) + калибровка.

MVP:

- Fine-tuning текстового классификатора (RuBERT-подобный) на транскриптах Dusha (4 класса) (developers.sber.ru).
- Затем **доменная адаптация**: дообучение/калибровка на небольшой ручной разметке реплик из реальных звонков (пилотный датасет).

Формирование выборок:

- Train/val/test на Dusha + отдельный “real calls test” (ручная разметка) для честной оценки переноса.
- Стратификация по классам, контроль leakage (не смешивать близкие фрагменты одного источника между сплитами, если применимо).

Метрики качества (технические):

- Macro-F1 по 4 классам (устойчиво к дисбалансу).
- Per-class F1 (особенно “злость” как бизнес-критичный класс).
- Calibration (ECE/Brier) — чтобы уверенности можно было использовать для фильтров.

Связь с бизнесом:

- Для супервизоров важнее **precision@topK** на “проблемных звонках” (чтобы top-список действительно был негативным), чем средняя точность по всем репликам.
- Поэтому дополнительно: качество ранжирования звонков по “негативному индексу” (см. этап 5) на ручной разметке звонков.

Этап 5 — Агрегации и “индексы” звонка

На базе реплик (speaker, timestamps, emotion, score):

- “Негативный индекс клиента”: доля (злость+грусть) у клиента, длительность негативных отрезков.
- “Негативный индекс оператора”: аналогично (важно для оценки коммуникации).
- “Пиковые моменты”: топ-N интервалов по суммарной вероятности злости/грусти.
- “Эскалации”: резкий рост негатива после определенной реплики (полезно для коучинга).

Выход этапа:

- Таблица `utterances` (call_id, speaker, start, end, text, emotion, probs…)
- Таблица `call_scores` (call_id, индексы, флаги, ссылки на таймкоды)

Этап 6 — Инференс-пайплайн (batch)

- Триггер: появление новой суточной папки в 00:00.
- Оркестрация: cron/Airflow/Prefect (что принято в компании).
- Параллелизм: обработка по звонкам (task queue).
- Повторяемость: versioning модели (ASR/Emotion), фиксация параметров, логирование.

Этап 7 — Мониторинг качества (минимум для MVP)

- Data quality: доля битых файлов, распределение длительностей, доля “пустых” транскриптов.
- ASR proxy: длина текста на минуту аудио, доля “неразборчиво”.
- Emotion drift: распределение классов по дням/операторам, резкие сдвиги.
- Quality sampling: ежедневная/еженедельная ручная проверка top негативных звонков.

---

3. Подготовка пилота

3.1. Способ оценки пилота

Дизайн:

- 2 группы супервизоров/команд:
  - Control: текущий процесс QA.
  - Test: QA с использованием системы (список top негативных звонков + таймлайн).
- Длительность пилота: 4 недели (чтобы покрыть недельную сезонность, смены и повторяемые сценарии обращений).

Сбор “ground truth”:

- Разметка части звонков: эмоции по репликам или хотя бы “звонок проблемный/не проблемный”.
- Можно разметить только сэмплы (например, top-список + случайная выборка).

3.2. Что считаем успешным пилотом

Бизнес-метрики (PO):

- **Метрика B1. Снижение времени разбора 1 звонка (мин/звонок):**
  - Цель: медианное время разбора звонка в `Test` ниже `Control` минимум на **30%**.
  - Как измеряем: от открытия карточки звонка до фиксации результата QA по одинаковым типам кейсов; считаем по неделям пилота.
  - Зачем используем: это прямой показатель экономии времени QA и основной ожидаемый бизнес-эффект от внедрения системы.
- **Метрика B2. Рост пропускной способности QA (звонков на супервизора):**
  - Цель: количество разобранных звонков на 1 супервизора в неделю в `Test` выше `Control` минимум на **50%** без увеличения штата.
  - Как измеряем: число завершенных QA-разборов на сотрудника за неделю, нормализованное на фактически отработанное время.
  - Зачем используем: подтверждает, что экономия времени конвертируется в большее покрытие контроля, а не только в ускорение отдельных кейсов.
- **Метрика B3. Точность top-списка проблемных звонков (доля релевантных среди top-N):**
  - Цель: среди `top-N` звонков, рекомендованных системой как проблемные, не менее **80%** подтверждаются QA как действительно требующие внимания.
  - Как измеряем: ручная проверка рекомендованного списка; `N` задается как дневная квота разбора (например, 30 звонков на супервизора в день).
  - Зачем используем: измеряет практическую полезность ранжирования для супервизора и напрямую влияет на доверие к системе.
- **Метрика B4. Покрытие контроля качества (доля звонков, прошедших QA):**
  - Цель: доля звонков, прошедших QA-проверку, в `Test` растет минимум в **1.5 раза** относительно исторического baseline по тем же очередям.
  - Как измеряем: число проверенных QA звонков / общее число звонков за период, отдельно по очередям/командам.
  - Зачем используем: фиксирует ключевую бизнес-цель пилота: перейти от выборочного контроля к существенно более широкому покрытию.

Технические метрики (DS):

- **Метрика T1. Macro-F1 по эмоциям на ручной разметке реплик (real calls test):**
  - Цель: `Macro-F1 >= 0.60` по 4 классам эмоций.
  - Как измеряем: на отдельном тестовом наборе реплик из реальных звонков с ручной разметкой, не использованном для калибровки.
  - Зачем используем: это базовый контроль качества модели эмоций при дисбалансе классов; без него бизнес-метрики могут быть нестабильны.
- **Метрика T2. Precision@K по проблемным звонкам (оффлайн-оценка ранжирования):**
  - Цель: `Precision@K >= 0.80`, где `K` соответствует дневной квоте ручной проверки.
  - Как измеряем: ранжируем звонки по негативному индексу и сверяем top-K с ручной меткой “проблемный/не проблемный”.
  - Зачем используем: это технический прокси к метрике B3 и показатель того, что система умеет правильно приоритизировать звонки.
- **Метрика T3. Batch SLA готовности результатов:**
  - Цель: не менее **95%** суточных батчей завершаются до **06:00** по локальному времени.
  - Как измеряем: по логам оркестратора, как время завершения обработки суточной папки.
  - Зачем используем: если результаты не готовы к началу смены QA, бизнес-эффект пилота не реализуется даже при хорошем качестве моделей.

3.3. Подготовка пилота (ресурсы/ограничения)

- Основные затраты: ASR. VibeVoice-ASR рассчитан на long-form и дает структурный вывод (speaker/timestamps) (huggingface.co), потенциально уменьшая число отдельных сервисов.
- На baseline-эксперименте:
  - замеряем реальную скорость обработки (RTF) и потребление GPU,
  - считаем суточный объем аудио → требуемое число GPU/воркеров,
  - определяем лимит пилота (например, обработка 100% звонков или только части очередей).

---

4. Внедрение (для MVP, ориентированного на дальнейший production)

4.1. Архитектура решения (верхнеуровнево)

- Storage:
  - Raw audio (как есть) + preprocessed audio (опционально).
  - Transcripts JSON.
  - Таблицы результатов (Postgres/ClickHouse) + объектное хранилище для артефактов.
- Compute:
  - Worker'ы ASR (GPU).
  - Worker'ы эмоций (GPU/CPU, зависит от модели).
- Orchestrator:
  - Airflow/Prefect + очередь задач (RabbitMQ/Kafka/Redis queue).
- Consumer:
  - Дашборд (PowerBI/Metabase) или веб-страница "карточка звонка".

4.2. Инфраструктура и масштабируемость

Выбор (предложение):

- Контейнеризация (Docker), запуск worker'ов в Kubernetes (если доступно) или на выделенных VM.
- Горизонтальное масштабирование по числу звонков.
- Кеширование/повторный запуск: идемпотентные джобы (call_id как ключ).

Почему так лучше альтернатив (DS):

- Простой рост мощности добавлением воркеров.
- Разделение тяжелого ASR и легкого постпроцессинга.

4.3. Требования к работе системы (SLA)

- Batch SLA (MVP): результаты по всем звонкам “вчера” готовы к 06:00 (локальное время площадки колл-центра).
- Пропускная способность: обработка суточного объема аудио ≤ окно обработки (например, 6 часов).

4.4. Безопасность системы

- RBAC: доступ к аудио/текстам только у QA/уполномоченных ролей.
- Аудит доступа (логи).
- Сегментация окружений (dev/test/prod).

4.5. Безопасность данных

- Потенциально применимы требования GDPR/локальных регуляций (зависит от юрисдикции компании и характера данных).
- Меры:
  - шифрование “at rest” и “in transit”,
  - политика ретеншна (например, хранить транскрипты меньше, чем raw audio),
  - решение по маскированию ПДн (ФИО/телефон/адрес) фиксируется до старта пилота; если тексты доступны в интерфейсе QA, включаем маскирование перед публикацией в витрину.

4.6. Издержки

- В пилоте считаем по формуле:
  - `Compute_cost ≈ (суммарные часы аудио / скорость_обработки_на_GPU) * стоимость_GPU_часа`
- Фактические цифры получить после baseline замеров на реальном железе.

4.7. Integration points

- Ingest: доступ к файловому архиву (SFTP/SMB/S3/FS mount).
- Экспорт результатов:
  - таблица/витрина (SQL),
  - API: `GET /calls/{id}`, `GET /calls?date=...&negativity>...`.
- (Опционально) интеграция с CRM/QA системой: прикрепление ссылки на “карточку звонка”.

4.8. Риски и неопределенности

- **Качество diarization**: ошибки “кто говорит” ухудшат интерпретацию эмоций (клиент vs оператор).
- **Domain shift**: эмоции в Dusha (вирт. ассистент/подкасты) могут отличаться от колл-центра (arxiv.org) → нужен доменный датасет/калибровка.
- **Юридические ограничения**: хранение транскриптов может требовать отдельного согласования.
- **Шум/акценты/код-свитч**: может снизить качество ASR → hotwords/контекст и аудио-препроцессинг (huggingface.co).